



MATERIAL DE CÁTEDRA-TEMA 1

INTRODUCCIÓN A LA ESTADÍSTICA



CARRERAS:

- **Lic. en Sistema**
- **Prof. en Computación**
- **Analista en sistema**

DOCENTES:

- **Adjunto: Esp. Rolón Esteban Eduardo**
- **JTP : Matías Corvo**
- **JTP : María Florencia Puente**

TABLA DE CONTENIDO

0. Introducción

1. La Estadística

1.1 Importancia y Definición

1.2 Conceptos fundamentales

2. Conceptos fundamentales

2.1 Etapas del Método Estadístico

- 1) Planteamiento del problema
- 2) Fijación de los objetivos
- 3) Formulación de las hipótesis
- 4) Definición de la unidad de observación y de la unidad de medida
- 5) Determinación de la población y de la muestra
- 6) La recolección
- 7) Crítica, clasificación y ordenación
- 8) La tabulación
- 9) La presentación
- 10) El análisis
- 11) Publicación

2.2. Conceptos claves

3. Distribución de Frecuencias

3.1 Distribución de frecuencias simple Ejercicios

3.2 Distribución de frecuencias por intervalo

3.3 Reglas empíricas para la construcción de Intervalos

4. Representación Gráfica

4.1 Gráficos para variables cualitativas

4.1.1 Diagrama de Barras

4.1.2 Diagramas de sectores (tortas, polares)

4.1.3 Pictogramas

4.2 Gráficos para variables cuantitativas

4.2.2 Diagramas barras para v. discretas

4.2.3 Diagramas diferenciales (frecuencia y ojiva)

4.2.3 Histogramas para v. continuas

4.3 Gráficos para variables cuantitativas según variables cualitativas

4.3.1 Gráficos de cajas y bigotes (Box-Plot)

4.3.2 Gráficos de Dispersión de puntos

5. Medidas de Tendencia Central

5.1 Media aritmética

5.1.1 Propiedades de la media aritmética

5.1.2 Media aritmética con cambio origen y de escala

5.1.3 Media aritmética ponderada

5.2 Mediana

5.2.1 La mediana para datos que no están agrupados en intervalos

5.2.2 La mediana para información agrupada en intervalos

5.3 La Moda

5.3.1 La moda para datos que no están agrupados en intervalos

5.3.2 Cálculo de la moda para datos agrupada en intervalos

6. Medidas de Posición (Percentiles)

6.1 Cuartiles

6.2 Quintiles

6.3 Deciles

6.4 Centiles

7. Medidas de Dispersión

7.1 Rango o recorrido

7.2 Desviación típica o estándar

7.3 Varianza o variancia

7.4 Coeficiente de variabilidad

8. Medidas de forma (Opcional)

8.1 Asimetría

8.2 Kurtosis

INTRODUCCIÓN

La palabra estadística se origina, en las técnicas de recolección, organización, conservación, y tratamiento de los datos propios de un estado, con que los antiguos gobernantes controlaban sus súbditos y dominios económicos. Estas técnicas evolucionaron a la par con el desarrollo de las matemáticas, utilizando sus herramientas en el proceso del análisis e interpretación de la información. De esta manera se integró la matemática específicamente las teorías vinculadas a la Probabilidad con la Estadística

La Probabilidad y la Estadística se encargan del estudio del azar desde el punto de vista de las matemáticas:

- **La Probabilidad** propone modelos para los fenómenos aleatorios, es decir, los que se pueden predecir con certeza, y estudia sus consecuencias lógicas.
- **La Estadística** ofrece métodos y técnicas que permiten entender los datos a partir de modelos.

De esta manera, **el Cálculo de las Probabilidades** es una teoría matemática y **la Estadística** es una ciencia aplicada donde hay que dar un contenido concreto a la noción de probabilidad.

En este sentido, el cálculo científico de probabilidades puede ayudarnos a **comprender lo que en ocasiones la intuición nos indica de manera errónea**. Un ejemplo típico es la denominada "paradoja de los cumpleaños". Supongamos que estamos en un grupo de 23 personas. Los cálculos nos dicen que la probabilidad de que dos personas celebren el mismo día su cumpleaños es del 50%, algo que a simple vista parece increíble (Paradoja del Cumpleaños »). No es de extrañar por tanto que la Teoría de Probabilidad se utilice en campos tan diversos como **la demografía, la medicina, las comunicaciones, la informática, la economía y las finanzas**.

Cuando hablamos de estadística, se suele pensar en **un conjunto de datos numéricos** presentado de forma ordenada y sistemática. Esta idea es debida a la influencia de nuestro entorno, ya que hoy día es casi imposible que cualquier medio de comunicación, periódico, radio, televisión, etc, no nos aborde diariamente con cualquier tipo de información estadística.

Sólo cuando nos adentramos en un mundo más específico como es **el campo de la investigación de las Ciencias Sociales: Medicina, Biología, Psicología, Genética** ... empezamos a percibir que la Estadística no sólo es algo más, sino que se convierte en la única herramienta que, hoy por hoy, permite dar luz y obtener resultados, y por tanto beneficios, en cualquier tipo de estudio, cuyos movimientos y relaciones, por su variabilidad intrínseca, no puedan ser abordadas desde la perspectiva de las leyes deterministas.

La Estadística se ocupa de los métodos y procedimientos para recoger, clasificar, resumir, hallar regularidades y analizar los datos (**Estadística Descriptiva**), siempre y cuando la variabilidad e incertidumbre sea una causa intrínseca de los mismos; así como de realizar inferencias a partir de

ellos, con la finalidad de ayudar a la toma de decisiones y en su caso formular predicciones (**Estadística Inferencial**). Link de profundización :

- [Historia de la Probabilidad](#)
- [Historia de la Estadística](#)
- [Historia de la Combinatoria](#)

En nuestros días, son de uso cotidiano las diferentes técnicas estadísticas que partiendo de observaciones muestrales o históricas, crean modelos lógico-matemáticos que se "aventuran" describir o pronosticar un determinado fenómeno con cierto grado de certidumbre medible.

La estadística, entonces, dejó de ser una técnica exclusiva de los estados, para convertirse en una herramienta imprescindible de todas las ciencias.

La estadística hace inferencias sobre una población, partiendo de una muestra representativa de ella. Es a partir del proceso del diseño y toma de la muestra desde donde comienzan a definirse las bondades y confiabilidad de nuestras aseveraciones, hechas, preferentemente, con un mínimo costo y mínimo error posible.

El avance tecnológico en la informática ha contribuido enormemente al desarrollo de la estadística, sobre todo en la manipulación de la información, pues en el mercado existen paquetes estadísticos de excelente calidad, como el INFOSTAT, R-STUDIO, SAS, SPSS, SCA, STATGRAPHICS, amén de otros, que "corren" en un ordenador sin mayores exigencias técnicas, permitiendo el manejo de grandes volúmenes de información y de variables.

BIOESTADISTICA (LÍNEA DE TIEMPO)

La bioestadística es una rama de la estadística que se ocupa de los problemas planteados dentro de las ciencias de la vida, como la biología, la medicina, entre otros.

Fuente: Estadística para todos : http://www.estadisticaparatodos.es/historia/histo_proba.html

1. LA ESTADÍSTICA

1.1 IMPORTANCIA Y DEFINICIÓN

En las últimas décadas la estadística ha alcanzado un alto grado de desarrollo, hasta el punto de incursionar en la totalidad de las ciencias; inclusive, en la lingüística se aplican técnicas estadísticas para esclarecer la paternidad de un escrito o los caracteres más relevantes de un idioma.

La estadística es una **ciencia auxiliar** para todas las ramas del saber; su utilidad se entiende mejor si tenemos en cuenta que los quehaceres y decisiones diarias embargan cierto grado de incertidumbre... y la Estadística ayuda en la incertidumbre, trabaja con ella y nos orienta para tomar las decisiones con un determinado grado de confianza.

Definir la estadística es una tarea difícil porque tendríamos que definir cada una de las técnicas que se emplean en los diferentes campos en los que interviene. Sin embargo, diremos, en forma general, que la estadística es un conjunto de técnicas que, partiendo de la observación de fenómenos, permiten al investigador obtener conclusiones útiles sobre ellos.

La estadística se divide en dos grandes ramas de estudio que son: *La estadística descriptiva*, la cual se encarga de la recolección, clasificación y descripción de datos muestrales o poblacionales, para su interpretación y análisis, que es de la que nos ocuparemos en este curso; y *la estadística matemática o inferencial*, que desarrolla modelos teóricos que se ajusten a una determinada realidad con cierto grado de confianza.

Estas dos ramas no son independientes; por el contrario, son complementarias y entre ambas dan la suficiente ilustración sobre una posible realidad futura, con el fin de que quien tenga poder de decisión, tome las medidas necesarias para transformar ese futuro o para mantener las condiciones existentes.

2. CONCEPTOS FUNDAMENTALES

2.1.1 ETAPAS DEL MÉTODO ESTADÍSTICO

El método estadístico, parte de la observación de un fenómeno, y como no puede siempre mantener las mismas condiciones predeterminadas o a voluntad del investigador, deja que actúen libremente o realiza un diseño experimental para poder manipular algunas variables, que luego se registran las diferentes observaciones y se analizan sus variaciones. Para el planeamiento de una investigación, por norma general, se siguen las siguientes etapas:

- 1) **Planteamiento del problema.**
- 2) **Fijación de los objetivos.**
- 3) **Formulación de la hipótesis.**
- 4) **Definición de la unidad de observación y de la unidad de medida.**

- 5) **Determinación de la población y de la muestra.**
- 6) **La recolección.**
- 7) **Crítica, clasificación y ordenación.**
- 8) **Tabulación.**
- 9) **Presentación.**
- 10) **Análisis.**
- 11) **Publicación.**

1) Planteamiento del problema

Al abordar una investigación se debe tener bien definido qué se va a investigar y por qué se pretende estudiar algo. Es decir, se debe establecer una delimitación clara, concreta e inteligible sobre el o los fenómenos que se pretenden estudiar, para lo cual se deben tener en cuenta, entre otras cosas, la revisión bibliográfica del tema, para ver su accesibilidad y consultar los resultados obtenidos por investigaciones similares, someter nuestras proposiciones básicas a un análisis lógico; es decir, se debe hacer una ubicación histórica y teórica del problema.

2) Fijación de los objetivos

Luego de tener claro lo que se pretende investigar, Debemos presupuestar hasta dónde queremos llegar; en otras palabras, debemos fijar cuales son nuestras metas y objetivos. Estos deben plantearse de tal forma que no haya lugar a confusiones o ambigüedades y debe, además, establecerse diferenciación entre lo de corto, mediano y largo plazo, así como entre los objetivos generales y los específicos.

3) Formulación de las hipótesis

Una hipótesis es ante todo, una explicación provisional de los hechos objeto de estudio, y su formulación depende del conocimiento que el investigador posea sobre la población investigada. Una hipótesis estadística debe ser susceptible de probarse su veracidad, esto es, debe poderse probar para su aceptación o rechazo.

Una hipótesis que se formula acerca de un parámetro (media, proporción, varianza, etc.), con el propósito de rechazarla, se llama Hipótesis de Nulidad y se representa por H_0 ; a su hipótesis contraria se le llama Hipótesis Alternativa (H_1).

4) Definición de la unidad de observación y de la unidad de medida

La Unidad de Observación, entendida como cada uno de los elementos constituyentes de la población estudiada, debe definirse previamente, resaltando todas sus características; pues, al fin de cuentas, es a ellas a las que se les hará la medición.

La unidad de observación puede estar constituida por uno o varios individuos u objetos y denominarse respectivamente simple o compleja.

El criterio sobre la unidad de medición debe ser previamente definido y unificado por todo el equipo de investigación. Si se trata de medidas de longitud, volumen, peso, etc., debe establecerse bajo qué unidad se tomarán las observaciones ya sea en metros, pulgadas, libras, kilogramos, etc.

Asociado a la unidad de medida, deben establecerse los criterios sobre las condiciones en las cuales se ha de efectuar la toma de la información.

5) Determinación de la población y de la muestra

Estadísticamente, **la población** se define como un conjunto de individuos o de objetos que poseen una o varias características comunes y se quiere estudiar. No se refiere esta definición únicamente a los seres vivos; una población puede estar constituida por los habitantes de un país o por los peces de un estanque, así como por los establecimientos comerciales de un barrio o las unidades de vivienda de una ciudad.

Existen desde el punto de vista de su manejabilidad poblaciones finitas e infinitas. Aquí el término infinito no está siendo tomado con el rigor semántico de la palabra; por ejemplo, los peces dentro de un estanque son un conjunto finito; sin embargo, en términos estadísticos, puede ser considerado como infinito.

Muestra es un subconjunto de la población a la cual se le efectúa la medición con el fin de estudiar las propiedades del conjunto del cual es obtenida.

En la práctica, estudiar todos y cada uno de los elementos que conforman la población no es aconsejable, ya sea por la poca disponibilidad de recursos, por la homogeneidad de sus elementos, porque a veces es necesario destruir lo que se está midiendo, por ser demasiado grande el número de sus componentes o no se pueden controlar; por eso se recurre al análisis de los elementos de una muestra con el fin de hacer inferencias respecto al total de la población.

Existen diversos métodos para calcular el tamaño de la muestra y también para tomar los elementos que la conforman, pero no es el objetivo de este curso estudiarlos.

Diremos solamente que la muestra debe ser representativa de la población y sus elementos escogidos al azar para asegurar la objetividad de la investigación.

6) La recolección

Una de las etapas más importantes de la investigación es la recolección de la información, la cual ha de partir, a menos que se tenga experiencia con muestras análogas, de una o varias muestras piloto en las cuales se pondrán a prueba los cuestionarios y se obtendrá una aproximación de la variabilidad de la población, con el fin de calcular el tamaño exacto de la muestra que conduzca a una estimación de los parámetros con la precisión establecida.

El establecimiento de las fuentes y cauces de información, así como la cantidad y complejidad de las preguntas, de acuerdo con los objetivos de la investigación son decisiones que se han de tomar teniendo en cuenta la disponibilidad de los recursos financieros, humanos y de tiempo y las limitaciones que se tengan en la zona geográfica, el grado de desarrollo, la ausencia de técnica, etc.

Es, entonces, descubrir dónde está la información y cómo y a qué "costo" se puede conseguir; es determinar si la encuesta se debe aplicar por teléfono, por correo, o si se necesitan agentes directos que recojan la información; establecer su número óptimo y preparar su entrenamiento adecuado.

7) Crítica, clasificación y ordenación

Después de haber reunido toda la información pertinente, se necesita la depuración de los datos recogidos. Para hacer la crítica de una información, es fundamental el conocimiento de la población por parte de quien depura para poder detectar falsedades en las respuestas, incompreensión a las preguntas, respuestas al margen, amén de todas las posibles causas de nulidad de una pregunta o nulidad de todo un cuestionario.

Separado el material de "desecho" con la información depurada se procede a establecer las clasificaciones respectivas y con la ayuda de hojas de trabajo, en las que se establecen los cruces necesarios entre las preguntas, se ordenan las respuestas y se preparan los modelos de tabulación de las diferentes variables que intervienen en la investigación. El avance tecnológico y la popularización de los computadores hacen que estas tareas, manualmente dispendiosas, puedan ser realizadas en corto tiempo.

8) La tabulación

Una **tabla** es un resumen de información respecto a una o más variables, que ofrece claridad al lector sobre lo que se pretende describir; para su fácil interpretación una tabla debe tener por lo menos: Un título adecuado el cual debe ser claro y conciso. La Tabla propiamente dicha con los correspondientes subtítulos internos y la cuantificación de los diferentes ítems de las variables, y las notas de pie de cuadro que hagan claridad sobre situaciones especiales de la tabla, u otorguen los créditos a la fuente de la información.

9) La presentación

Una información estadística adquiere más claridad cuando se presenta en la forma adecuada. Los cuadros, tablas y gráficos facilitan el análisis, pero se debe tener cuidado con las variables que se van a presentar y la forma de hacerlo. No es aconsejable saturar un informe con tablas y gráficos redundantes que, antes que claridad, crean confusión. Además la elección de determinada tabla o gráfico para mostrar los resultados, debe hacerse no sólo en función de las variables que relaciona, sino del lector a quien va dirigido el informe.

10) El análisis

La técnica estadística ofrece métodos y procedimientos objetivos que convierten las especulaciones de primera mano en aseveraciones cuya confiabilidad puede ser evaluada y ofrecer una premisa medible en la toma de una decisión.

Es el análisis donde se cristaliza la investigación. Esta es la fase de la determinación de los

parámetros y estadísticos muestrales para las estimaciones e inferencias respecto a la población, el ajuste de modelos y las pruebas de las hipótesis planteadas, con el fin de establecer y redactar las conclusiones definitivas.

11) Publicación

Toda conclusión es digna de ser comunicada a un auditorio. Es más, hay otros estudiosos del mismo problema a quienes se les puede aportar información, conocimientos y otros puntos de vista acerca de él.

2.1.1 CONCEPTOS CLAVES

Unidad de análisis (UA): es un elemento, una persona o un objeto individual de estudio que pertenece al conjunto mayor que se denomina población, del cual se tiene interés en conocer o describir algún situación o fenómeno en particular.

Población o universo: Representa el conjunto de todas las unidades de análisis que conformar el grupo de objetos o personas que se quiere estudiar. El tamaño de la población si es conocido (finito) se representa con N .

Muestra: subconjunto de una población. El tamaño se representa con n .



- **Población (universo):** es el conjunto total sobre el que estamos interesados en obtener conclusiones (hacer inferencia).
 - Normalmente es demasiado grande para poder abarcarlo.

- **Muestra: es un subconjunto suyo al que tenemos acceso y sobre el que realmente hacemos las observaciones (mediciones)**
 - Debe ser “representativo”
 - Esta formado por miembros “seleccionados” de la población (individuos, unidades experimentales).

fig.1

Parámetro: es cualquier función que determine numéricamente una característica de una población. Por ejemplo el **promedio de edad (μ)** de los alumnos ingresantes, proporción de mujeres de los ingresantes (P), proporción de alumnos de apóstoles de los ingresantes, ect...

También se puede decir que es una característica de la población expresada numéricamente. Se usan letras griegas o la mayúsculas para nombrar a los parámetros

Estadístico (o estimador) : es cualquier característica numérica de una muestra. Por ejemplo el Promedio de edad de un grupo de ingresantes elegidos al azar ($\bar{x}$), proporción de mujeres ingresantes dentro de este grupo (p), etc....

Variables: propiedades, rasgos o cualidades de los elementos de la población. En otras palabras, es cada propiedad o aspecto que es objeto de estudio sobre los individuos.

- Cuando una variable es susceptible de medir, contar, o comparar, se denomina **carácter cuantitativo** (puede ser **discreto o continuo**).
- Cuando es observable y no mensurable numéricamente se dice que es **cualitativa**. Puede ser **Nominal** (sin un criterio de orden , por ejemplo sexo : varón /mujer) u **Ordinal** por ejemplo grado de motivación (bajo-medio – alto)

3. DISTRIBUCIÓN DE FRECUENCIA

Una variable estadística permite realizar una clasificación de los individuos de una población que se consideran como equivalentes. Se colocan en una misma clase las unidades estadísticas que se consideran equivalentes. Cada clase se llama **modalidad** del carácter estadístico.

Veamos un caso concreto supongamos que tenemos 380 alumnos sentados de 1° a 7° de la Esc. N° 144 de San Pedro, Misiones (Imagen 2) sentados sin ningún criterio específico .



Imagen 1: Alumnos de primaria de San Pedro

Se los puede reorganizar según diferentes variables: Por ejemplo según:

Turno: Tarde y mañana

Sexo : Femenino y Masculino

Grado: de 1° a 7° (siete modalidades)

Edad : DE 6 A 14 años

Peso: de 20 kg a 80 kg

Altura : 1.10 m a 1.80 m

De esta manera tendré seis formas diferentes de distribuirlos, por un lado tendré según turno, un grupo de 120 niños del turno tarde y otro de 260 de la mañana. Por otra parte según el sexo tendré 185 mujeres y 195 hombres.

Y así incluso podría armar tablas donde distribuiría las cantidades (frecuencia) de alumnos según cada variable, este hecho de contar las cantidades según agrupamientos en estadística se llaman funciones de distribución de frecuencia, ver las tablas :

Tablas de distribución de frecuencia según: (a) Turno, (b) Sexo, c) Grado y (d) Edad

(a)Turno	Frecuencia
Tarde	120
Mañana	260
Total	380

(b)Sexo	frec.
Femenino	185
Masculino	195
Total	380

(c) Grado	Frecuencia
1°	70
2°	63
3°	62
4°	65
5°	47
6°	38
7°	35
Total	380

(d)Edad	Frecuencia
6 – 7	113
8 – 9	108
10- 11	81
12- 13	63
13-14	15
Total	380

Organización de datos mediante tablas: El objetivo de la organización de datos es acomodar un conjunto de datos en forma útil para revelar sus características esenciales y simplificar ciertos análisis.

Distintos Tipos de Frecuencia: Una de los primeros pasos que se realizan en cualquier estudio estadístico es la tabulación de resultados, es decir, recoger la información de la muestra resumida en una tabla en la que a cada modalidad se le asocian determinados números que representan el número de veces que ha aparecido, su proporción con respecto a otros valores de la variable, etc. Estos números se denominan *frecuencias*: Así tenemos los siguientes tipos de frecuencia:

Frecuencia absoluta: La frecuencia absoluta de una variable estadística es el número de veces que una modalidad ha sido observada, es decir el número de veces que aparece en la muestra dicho valor de la variable. Se utiliza la letra f_i o n_i con subíndice i para indicar cualquier frecuencia:

f_i = cantidad de unidades de análisis de la modalidad “i”

Frecuencia relativa: La frecuencia absoluta, es una medida que está influida por el tamaño de la muestra, al aumentar el tamaño de la muestra aumentará también el tamaño de la frecuencia absoluta. Esto hace que no sea una medida útil para poder comparar. Para esto es necesario introducir el concepto de *frecuencia relativa*, que es el cociente entre la frecuencia absoluta y el tamaño de la muestra.

$$h_i = Fr = \frac{f_i}{N} = \frac{\text{frecuencia absoluta}}{\text{cantidad de UA de la población o muestra}} \quad (\text{se puede multiplicar por 100})$$

Tabla 1: Distribución de frecuencia de los alumnos según el grado que asisten.

Turno x	Frec. absoluta (fi)	frec. relativa (hi)	frec. acumulada (Fi)	frec relativa acumulada (Hi)
1°	70	$70/380=0.1842$	70	$70/380= 0.1842$
2°	63	$63/380= 0.1658$	$70+63=133$	0.3500
3°	62	0.1632	$133+62= 195$	0.5132
4°	65	0.1711	260	0.6842
5°	47	0.1237	307	0.8079
6°	38	0.1000	345	0.9079
7°	35	0.0921	380	1
Total	380	1		

Porcentaje o Frecuencia relativa porcentual :La frecuencia relativa es un *tanto por uno*, sin embargo, hoy día es bastante frecuente hablar siempre en términos de *tantos por ciento o porcentajes*, por lo que esta medida resulta de multiplicar la frecuencia relativa por 100.

$$hi \% = Fr \% = \frac{fi}{N} \cdot 100$$

Frecuencia Absoluta Acumulada: Para poder calcular este tipo de frecuencias hay que tener en cuenta que la variable estadística ha de ser cuantitativa o cualitativa ordenable. En otro caso no tiene mucho sentido el cálculo de esta frecuencia. La frecuencia absoluta acumulada de un valor de la variable, es el número de veces que ha aparecido en la muestra un valor menor o igual que el de la variable.

Frecuencia Relativa Acumulada: Al igual que en el caso anterior la frecuencia relativa acumulada es la frecuencia absoluta acumulada dividido por el tamaño de la muestra.

Porcentaje Acumulado: Análogamente se define el Porcentaje Acumulado como la frecuencia relativa acumulada por 100.

Intervalos de clase : Los intervalos se usan cuando la variable es cuantitativa continua o cuando los datos son discretos pero muy numerosos. Si la variable es continua las clases vendrán definidas mediante lo que denominamos **intervalos**. En este caso, las modalidades que contiene una clase son todos los valores numéricos posibles contenidos en el intervalo, el cual viene normalmente definido de la forma . En estos casos llamaremos **amplitud, longitud o ancho del intervalo** a la diferencia entre el extremo inferior del intervalo y el extremo inferior del intervalo siguiente.

La **marca de un intervalo** es un punto representativo del intervalo. Si éste es acotado, tomamos como marca de clase al punto más representativo, es decir al punto medio del intervalo,

La marca de clase no es más que una forma abreviada de representar un intervalo mediante uno de sus puntos. Por ello hemos tomado como representante, el punto medio del mismo. Esto está plenamente justificado si recordamos que cuando se mide una variable continua como el peso, la cantidad con cierto número de decimales que expresa esta medición, no es el valor exacto de la variable, sino una medida que contiene cierto margen de error, y por tanto representa a todo un intervalo del cual ella es el centro.

Ahora bien, si se quiere construir una tabla de frecuencias agrupadas para una cierta colección de datos, es necesario responder tres preguntas relativas a las clases:

1. ¿Cuántas clases deben usarse?
2. ¿Cuál debe ser la amplitud de clase?
3. ¿En qué valor debe empezar la primera clase?

1. ¿Cuántas clases deben usarse? VER [Pag. 25 Bioestadística 1-DANIEL](#)

Escoger el número de clases requiere varias consideraciones. Si todos los datos se agrupan en un número pequeño de clases, las características de los datos originales se ocultan y puede perderse información relevante, por otro lado, demasiadas clases dan demasiados detalles y se pierde el propósito de agrupamiento, que es condensar de manera significativa y fácil de interpretar. Además, demasiadas clases pueden dar lugar a que muchas clases queden vacías quitándole sentido al agrupamiento de los datos.

El número de clases depende de la situación y del total de los datos obtenidos. No hay un acuerdo general acerca del número de clases que deben usarse y aunque la elección es arbitraria, hay algunas reglas que pueden ayudar a encontrar una aproximación de este número. La raíz cuadrada del número de observaciones a menudo funciona bien, o la regla de Sturges: $C = 3,32 \cdot (\log n) + 1$

Por ejemplo en nuestro caso de nuestros 380 estudiantes, en los quedremos organizar según el peso para hallar la cantidad de clases realizamos $C = 3,32 \cdot \log(380) + 1 = 9,56 \approx 10$

2. ¿Cuál debe ser la amplitud de clase?

Una vez establecido el número de intervalos de clase que se usarán, la amplitud de clase se encuentra usando el **rango**(R), que es la diferencia entre la medida mayor (U) y la medida menor en la muestra (L)

Como C **clases** debe cubrir el **rango**, dividimos éste entre el número de clases para encontrar la **amplitud** de clase A ($A = R/C$) ; $R = 80 \text{ Kg} - 20 \text{ kg} = 60 \text{ kg}$ entonces $A = \frac{60 \text{ KG}}{10} = 6 \text{ KG}$

3. ¿En qué valor debe empezar la primera clase?

Como la medida menor debe caer en la primera clase, el límite inferior de la primera clase debe estar en, o un poco antes de, la medida menor L.

Tabla 2: Distribución de frecuencia de los alumnos según el peso.

Li - Ls	Marca	Frec.abs.	Frec.acum	hi%	Hi%
20 – 26	$(20+26)/2=23$	18	18	4.74	4.74
26 – 32	29	54	72	14.21	18.95
32 – 38	35	70	142	18.42	37.37
38 – 44	41	72 (a)	214	18.95(b)	56.32
44 – 50	47	65	279	17.11	73.42
50 – 56	53	36	315	9.47	82.89
56 – 62	59	23	338(c)	6.05	88.95(d)
62 – 68	65	18	356	4.74	93.68
68 - 74	71 (f)	14	370	3.68	97.37
74 - 80	77	10	380	2.63	100,00
		380		100,00	

Luego de haber armado la tabla completa en organización por intervalos de clase podemos interpretar algunos valores internos :


- (a) : 72 alumnos pesan entre 38 y 44 kg.
- (b) : 18.95% de los alumnos tienen entre 38 y 44 kg.
- (c) : 338 alumnos tienen 68 kg o menos , es decir pesan como máximo 68 kg.
- (d) : el 88,95 % no supera 62 kg , o tienen 62 o menos kilogramos.
- (e) : 71 kg es la marca de clase (representante) de los alumnos que pesan de 68 a 74 kg.

4. GRÁFICOS ESTADÍSTICOS

4.1 GRÁFICOS PARA V. CUALITATIVAS

4.1.1 Diagrama de Barras

- Alturas proporcionales a las frecuencias (abs. o rel.)
- Se pueden aplicar también a variables cuantitativas discretas
- Las barras están separadas




4.1.2 Diagramas de sectores (tortas, polares)

- No usarlo con variables ordinales o si se tiene más de seis modalidades
- El área de cada sector es proporcional a su frecuencia

Tabla 3

(a)Turno	Frecuencia
Tarde	120
Mañana	260
Total	380



4.1.3 Pictogramas

- Fáciles de entender.
- El área de cada modalidad debe ser proporcional a la frecuencia.



Gráfico 5


Revista : Educative , México , 2015

4.2 GRÁFICOS PARA V. CUANTITATIVAS

Son diferentes en función de que las variables sean discretas o continuas. Se pueden usar las con frecuencias . absolutas o las relativas.

4.2.1 Diagramas barras para v. discretas gráficos 6,7, y 8 .


Se deja un hueco entre barras para indicar los valores que no son posibles




4.2.2 Histogramas para v. continuas

El área que hay bajo el histograma entre dos puntos cualesquiera indica la cantidad (porcentaje o frecuencia) de individuos en el intervalo.

Gráfico 9: Distribución de frecuencia según edad de los encuestados (Histograma)



4.2.3 Gráfico10: Frecuencias acumuladas según concentración de glucosa (Ojiva)



4.3 VARIABLES CUANTITATIVAS SEGÚN VARIABLES CUALITATIVAS

4.3.1 Diagrama de cajas y bigotes

Este es uno de los gráficos más utilizado en las publicaciones científicas por su capacidad de representar la distribución de la variable, los valores centrales y los valores extraños (outliers)




Gráfico 11

4.4 VARIABLES CUANTITATIVAS SEGÚN OTRA CUANTITATIVA

4.4.1 Dispersión o Diagrama de puntos de puntos




Gráfico 12

5. MEDIDAS DE TENDENCIA CENTRAL

5.1 MEDIA ARITMÉTICA

La media aritmética ($\bar{X} = \mu$ o $\bar{x}$) o simplemente promedio es el parámetro de posición de más importancia en las aplicaciones estadísticas. Es la medida posicional más utilizada en los estudios estadísticos viene a ser el punto de equilibrio, es el centro de gravedad de la serie de datos. La media aritmética por lo general se le designa con $\bar{X}$ cuando es una la media muestral y μ (sigma) o $\bar{x}$ como media poblacional.

La media aritmética de una serie de N valores de una variable $x_i = \{x_1, x_2, x_3, x_4, \dots, x_n\}$ es el cociente de dividir la sumatoria de todos los valores que toma la variable X_i , entre el número total

de ellos. La formula se puede expresar así

$$\mu = \frac{\sum_{i=1}^n x_i}{N} = \frac{1}{N} \sum_{i=1}^n x_i$$

Desviaciones o desvíos: Son diferencias algebraicas entre cada valor de la serie o cada punto medio y la media aritmética de dicha serie, o un valor cualquiera tomado arbitrariamente. Los *desvíos* o *desviación* se designan con la letra d_i .

Dado una serie de valores $x_1, x_2, x_3, \dots, x_n$, se llama *desvío* a la diferencia entre un valor cualquiera x_i de la serie y un valor indicado k de esa misma serie. Si el valor indicado k de la serie corresponde precisamente a la media aritmética de esos valores dados, se dice entonces que los *desvíos* son con respecto a la media aritmética. En símbolo: $d_i = (X_i - \bar{X})$.

Características Principales de la Media Aritmética

1. La media se calcula con facilidad y es única para cada caso y permite representar mediante un solo valor la posición de la serie de valores.
2. El valor de la media depende de cada una de las medidas que forman la serie de datos.
3. Se halla afectada excesivamente o dicho de otro modo es muy sensible a los valores extremos de la serie de datos. Por ejemplo si tengo un grupo de 4 estudiantes de 17, 18, 18, 19 y 35 la media da 21,6 años, este número no representa a la mayoría, solo es un punto de equilibrio, se debe usar otra medida que se verá más adelante.

Cálculo de la media para datos no agrupados

Para calcular la media de datos no agrupados en clases se aplica la siguiente fórmula:

$\mu = \frac{\sum_{i=1}^n x_i}{N}$. En donde N es el número total de datos y x_i son los valores de la variable.

Ejemplo: Calcule la media aritmética de los siguientes valores: $X_i = \{5, 7, 8, 9, 11, 14\}$

$$\frac{\sum X_i}{N} = \frac{5+7+8+9+11+14}{6} = \frac{54}{6} = 9$$

Por lo tanto la media es $\mu = 9$

Cálculo de la media para datos agrupados

Cuando se construye una distribución de frecuencia, los datos se agrupan en clases definidas por unos límites. Cuando se trabaja con la distribución de frecuencia se parte del supuesto de que todos los datos comprendidos en un intervalo de clase se distribuyen uniformemente a lo largo de este, entonces se puede tomar la *marca de clase* o *punto medio* (x_m) del intervalo como adecuada representación de los valores que conforman el mencionado intervalo. El *punto medio* se designa con la letra (x_m). Para calcular la media en estas condiciones se pueden utilizar tres métodos: El método *directo* o *largo* y dos métodos *abreviados*.

Este método se le conoce también como método largo; el mismo resulta demasiado engorroso cuando las magnitudes de los puntos medios o de las frecuencias de clase son muy grandes, debido a que los cálculos son demasiados extensos. Los pasos a seguir para calcular la media con este método son los siguientes:

1. Se agrupan los datos en clases y se llevan a una columna, se calculan los puntos medios de cada clase y se colocan en sus respectivas columnas, se determinan las frecuencias de cada clase y se ubican en sus respectivas columnas.
2. Se multiplican los puntos medios de cada clase por sus respectivas frecuencias, luego se obtiene la sumatoria de las frecuencias (f_i) multiplicadas por el punto medio (x_{mi}) así: $\sum_{i=1}^n f_i \cdot x_{mi}$
3. Luego se calcula la media aritmética aplicando la formula: es igual al número total de datos. Ejemplo:

$$\mu = \frac{\sum_{i=1}^n f_i \cdot x_{mi}}{N}$$

1.-Calcule la media de la siguiente distribución de frecuencia correspondiente al peso en Kg de un grupo de obreros. Realice los cálculos respectivos para completar el siguiente cuadro.

(4) CLASES	x_m	f_i	$f_i \cdot x_{mi}$
75-----79	77	20	1540
80-----84	82	40	3280
85-----89	87	60	5220
90-----94	92	100	9200
95 -----99	97	140	13580
TOTAL		$\sum f_i = 360$	$= 32820$

Aplicando la formula se tiene:

$$\mu = \frac{32820}{360} = 91.17$$

B) LA MEDIANA

La mediana (M_d) es una medida de posición que divide a la serie de valores en dos partes iguales, un cincuenta por ciento que es mayor o igual a esta y otro cincuenta por ciento que es menor o igual que ella. Es por lo tanto, un parámetro que esta en el medio del ordenamiento o arreglo de los datos organizados, entonces, la mediana divide la distribución en una forma tal que a cada lado de la misma queda un número igual de datos.

Para encontrar la mediana en una serie de datos no agrupados, lo primero que se hace es ordenar los datos en una forma creciente o decreciente y luego se ubica la posición que esta ocupa en esa serie de datos; para ello hay que determinar si la serie de datos es par o impar. Si el número N de

datos es impar, entonces la posición de la mediana se determina por la formula: $p_{Md} = \frac{N+1}{2}$, luego

el número que se obtiene indica el lugar o posición que ocupa la mediana en la serie de valores, luego la mediana será el número que ocupe el lugar de la posición encontrada. Para obtener la posición de la mediana en una serie de datos no agrupados, en donde el número N de datos es par no se encuentra un solo número que divida en dos partes iguales la serie de datos.

Para solucionar esto habrá que obtener dos posiciones centrales $P_1 = N/2$ y la $P_2 = N/2 + 1$ y sacar el promedio entre los dos valores que se encuentren en esas posiciones. Veamos dos ejemplos.

- 1) Supomamos que tengamos siete datos : 10, 6, 6, 9, 8, 5, 12 los ordenamos de menor a mayor 5, 6, 6, 8, 9, 10, 12, si buscamos $P_m = (7+1)/2 = 4$ lo cual nos indica que Mediana es igual a 8.
- 2) Si tuvieramos un dato más ($N=8$) y lo ordenamos : 5, 6, 6, 8, 9, 9, 10, 12 vamos a determinar el promedio de los dos números centrales que ocupan las posiciones : $P_1 = N/2 = 8/2 = 4$ y $P_2 = 5$.

De esta manera vamos a la serie de datos que está ya ordenada de menor a mayor y concluimos que

la M_d viene a ser la semisuma de ambas posiciones $\left(\frac{8+9}{2} = 8.5 \right)$ en este caso 8.5 es la mediana

buscad, y esto es así, ya que el número 8.5 divide la serie de valores en dos partes iguales, una mitad que es mayor que la mediana y otra mitad que es menor que esta.

Cuando los valores de los datos brutos de un conjunto de datos se agrupan en una distribución de frecuencia de clase, cada valor pierde su identidad, por tal motivo la mediana obtenida de una distribución de frecuencia de datos puede no ser la misma que la mediana obtenida de los datos sin arreglar en clases, pero el resultado será una aproximación. Cuando se obtiene la mediana para datos agrupados se utiliza el método de interpolación. La interpolación parte del supuesto de que los datos de cada intervalo de la distribución están igualmente distribuidos.

Pasos para determinar la mediana en datos agrupados

1. – Se elabora la tabla de frecuencia de datos con sus diferentes intervalos de clases, se ubican las frecuencias f_i y se calculan las frecuencias acumuladas F_a de esa distribución.

2. – Se determina la ubicación o posición de la mediana en el intervalo de la distribución de frecuencia, mediante la fórmula $P_{Md} = \frac{N}{2}$. El resultado obtenido determinará la clase donde se encuentra ubicada la mediana, lo cual se conseguirá en la clase donde la frecuencia acumulada Fa

sea igual o superior a este resultado. Luego se aplica la formula: $Md = Li + \left[\frac{\frac{N}{2} - Faa}{fm} \right] Ic$, en esta

formula Md es la mediana, Li es el limite real inferior de la clase donde se encuentra ubicada la mediana, Faa es el valor de la frecuencia acumulada anterior a la clase donde se encuentra la mediana, fm es el valor de la frecuencia fi de la clase donde se encuentra la mediana, Ic es el valor o longitud del intervalo de clase y N es el número total de datos de la distribución en estudio.

1.- Dada la siguiente distribución de frecuencia referida a las horas extras laboradas por un grupo de programadores en sus hogares. Calcule la mediana. Realice los cálculos respectivos para completar el siguiente cuadro.

(5)N° de horas Extras	Programadores
CLASES	fi
55-----59	6
60-----64	20
65-----69	18
70-----74	50
75-----79	17
80-----84	16
85-----89	5
	N = 132

Solución: Tabla 6: Distribución de frecuencia de los programadores según las horas extras de trabajo

N° de horas Extras	Obreros	Obreros
CLASES	fi	fa
55-----59	6	6
60-----64	20	26
65-----69	18	44
70-----74	50	94
75-----79	17	111
80-----84	16	127
85-----89	5	132
	N = 132	

Ahora se aplica la formula:
$$Md = Li + \left[\frac{\frac{N}{2} - Faa}{fm} \right] Ic$$

$N = 132$, $\frac{N}{2} = \frac{132}{2} = 66$, luego la mediana se encuentra en la clase 70----74, por lo tanto el limite real inferior de esa clase es $69.5 = Li$. La frecuencia fi de esa clase es $50 = fm$, $Faa = 44$ y el

$Ic = 5$. Aplicando la formula se tiene:

$$Md = 69.5 + \left[\frac{66 - 44}{50} \right] 5 = 69.5 + \left(\frac{22}{50} \right) .5 = 69.5 + 2.2 = 71.70.$$

Luego la mediana de esa distribución es 71.70. Esto quiere decir que un 50 % de los programadores trabajaron horas extras por debajo de 71.70 horas y el otro 50 % trabajaron horas extras por encima de 71.70 horas.

Características de la mediana

- * La mediana no es afectada por los valores extremos de una serie de valores, puesto que la misma no es calculada con todos los valores de la serie.
- * La mediana no esta definida algebraicamente, ya que para su cálculo no intervienen todos los valores de la serie.
- * La mediana en algunos casos no se puede calcular exactamente y esto ocurre cuando en una serie de valores para datos no agrupados el número de datos es par, en este caso la mediana se calcula aproximadamente.
- * La mediana se puede calcular en aquellas distribuciones de frecuencia de clases abierta, siempre y cuando los elementos centrales puedan ser determinados.
- * La suma de los valores absolutos de las desviaciones de los datos individuales con respecto a la mediana siempre es mínima.

C) LA MODA

La moda es la medida de posición que indica la magnitud del valor que se presenta con más frecuencia en una serie de datos; es pues, el valor de la variable que más se repite en un conjunto de datos. De las medias de posición la moda es la que se determina con mayor facilidad, ya que se puede obtener por una simple observación de los datos en estudio, puesto que la moda es el dato que se observa con mayor frecuencia. La moda se designa con las letras *Mo*.

En las representaciones gráficas la moda es el punto más alto de la gráfica. La obtención de la moda para datos agrupados no es un valor exacto, ya que varía con las diferentes formas de agrupar una distribución de frecuencia.

En algunas distribuciones de frecuencias o serie de datos no agrupados o agrupados se presentan dos o más modas, en estos casos se habla de serie de datos bimodales o multimodales, según sea el caso. Estos tipos de distribuciones o series de valores se deben a la falta de homogeneidad de los datos.

Cuando una serie de valores es simétrica, la media, la mediana y el modo coinciden, y si la asimetría de la serie es moderada, la mediana estará situada entre la media y el modo con una separación de un tercio entre ambas. Tomando en cuenta esta relación, cuando se tengan dos de estas medidas se puede determinar la tercera; sin embargo es conveniente utilizar esta relación para calcular solamente la moda ya que para calcular la media y la mediana existen formulas matemáticas que dan resultados más exactos; la formula matemática para calcular la moda por medio de la relación antes mencionada es: $Mo = \bar{X} - 3(\bar{X} - Md)$.

Para calcular la moda en datos agrupados existen varios métodos; cada uno de los métodos puede dar un valor diferente de la moda: En este curso se dará un método el cual se puede considerar uno de los más precisos en el cálculo de esta. Es un método matemático que consiste en la interpolación mediante la siguiente fórmula:

$Mo = Li + \left(\frac{\Delta_1}{\Delta_1 + \Delta_2} \right) . Ic$, en donde Mo es la moda, Li es el límite real de la clase que presenta

el mayor número de frecuencia; la clase que presenta el mayor número de frecuencias fi se le denomina clase modal y a las frecuencias de esas clases se les denomina frecuencia modal fm , Δ_1 es la diferencia entre la frecuencia de la clase modal (fm) y la frecuencia de la clase anterior a la modal, la cual se designa con fa , entonces, $\Delta_1 = (fm - fa)$; Δ_2 es la diferencia entre la frecuencia de la clase modal (fm) y la frecuencia de la clase siguiente a la modal, esta se designa con fs , entonces, $\Delta_2 = (fm - fs)$.

1. – Dada la siguiente distribución de frecuencia correspondiente al peso en Kg de un grupo de estudiantes de la ciudad de Posadas, calcule la moda.

CLASES	fi
30-----39	2
40-----49	2
50-----59	7
60-----69	11
70-----79	12
80-----89	16
90-----99	2
TOTAL	

La clase modal es 80----89, entonces $Li = 79.5$ y su $fm = 16$, $fa = 12$ y $fs = 2$, $Ic = 10$, entonces:

$$\Delta_1 = f_m - f_a \rightarrow \Delta_1 = 16 - 12 = 4; \Delta_2 = f_m - f_s = 16 - 2 = 14$$

Aplicando la formula se tiene:

$$Mo = L_i + \left(\frac{\Delta_1}{\Delta_1 + \Delta_2} \right) \cdot Ic \rightarrow Mo = 79.5 + \left(\frac{4}{4 + 14} \right) \cdot 10 = 79.5 + \frac{40}{18} = 79.5 + 2.22 = 81.71.$$

Este resultado de la moda se interpreta así: La mayoría de los estudiantes tiene un peso aproximadamente de 81.71 Kg.

Características de la moda

- * El valor de la moda puede ser afectado grandemente por el método de elaboración de los intervalos de clases.
- * El valor de la moda no se halla afectado por la magnitud de los valores extremos de una serie de valores, como sucede en la media aritmética.
- * La moda se puede obtener en una forma aproximada muy fácilmente, puesto que la obtención exacta es algo complicado.
- * La moda tiene poca utilidad en una distribución de frecuencia que no posea suficientes datos y que no ofrezcan una marcada tendencia central.
- * No es susceptible de operaciones algebraicas posteriores.
- * La moda se utiliza cuando se trabaja con escalas nominales aunque se puede utilizar con las otras escalas.
- * La moda es útil cuando se esta interesado en tener una idea aproximada de la mayor concentración de una serie de datos.

OTRAS MEDIDAS POSICIONALES

Cuando se estudio la mediana se pudo detectar que esta divide la serie de valores en dos partes iguales, una generalización de esta medida da origen a unas nuevas medidas de posición denominadas:

Cuartiles; Deciles y Percentiles. Estas nuevas medidas de posición surgen por la necesidad de requerir de otras medidas que expresen diferentes situaciones de orden, aparte de las señaladas por la mediana. Por lo tanto es interesante ubicar otras medidas que fraccionen una serie de datos en diferentes partes. Es bueno destacar que los cuarteles, los Deciles y los Percentiles son unas variantes de la mediana: De la misma forma los percentiles abarcan tanto a los cuarteles como a los Deciles.

D) LOS CUARTILES.- Son medidas posicionales que dividen la distribución de frecuencia en cuatro partes iguales. Se designa por el símbolo Q_a en la que a corresponde a los valores 1, 2 y 3., que viene a ser el número de Q_a que posee una distribución de frecuencia de clase. El Q_1 divide la distribución de frecuencia en dos partes, una corresponde a 25 % que esta por debajo de Q_1 y el otro 75 % por encima de Q_1 . El Q_2 divide la distribución de frecuencia en dos partes iguales, un 50 % que esta por debajo de los valores de Q_2 y otro 50 % que esta por encima del valor de Q_2 . El Q_2 es igual a la mediana.

Cálculo de los cuartiles.- Para datos no agrupados no tiene ninguna utilidad practica calcular los cuartiles. Para el cálculo de los cuartiles en datos agrupados en una distribución de frecuencia existe un método por análisis gráfico y otro por determinación numérica, por fines prácticos en esta cátedra se utilizara el último método. Para calcular los cuartiles por el método numérico se procede de la siguiente manera:

1 – Se localiza la posición del cuartil solicitado aplicando la formula de posición: $P_{Qa} = \frac{aN}{4}$, en

donde a viene a ser el número del cuartil solicitado, N corresponde al número total de datos de la distribución y 4 corresponde al número de cuartiles que presenta una distribución de frecuencia.

2 – Luego se aplica la formula para determinar un cuartil determinado, así:

$$Q_a = Li + \left[\frac{\frac{aN}{4} - Faa}{fm} \right] . Ic. \text{ En esta formula, } Qa = \text{El cuartil solicitado, en esta } a \text{ corresponde al}$$

número del cuartil solicitado; Li = Limite real inferior de la clase donde se encuentra ubicado el cuartil; Faa = Frecuencia acumulada anterior a la clase donde se encuentra el cuartil; fm =

Frecuencia fi que posee el intervalo de clase donde se encuentra el cuartil; $P_{Qa} = \frac{aN}{4}$ = Posición

que ocupa el cuartil en la distribución de frecuencia, este resultado obtenido determinará la clase donde se encuentra ubicado el cuartil, el mismo se encontrará en la clase donde la frecuencia acumulada Fa sea igual o superior a este resultado.

E) DECILES. – Son medidas de posición que dividen la distribución de frecuencia en diez partes iguales y estas van desde el número uno hasta el número nueve. Los deciles se les designa con las letras D_a , siendo a , el número de los diferentes deciles, que en este caso son nueve. El D_2 es el punto debajo del cual se encuentran ubicados el 20 % de los valores de la distribución o también el punto por sobre el cual se encuentra el 80 % de los valores de la serie de datos. La mediana es igual al D_5 , puesto que este decil divide la distribución en dos partes iguales tal como lo hace la mediana, de la misma forma el decil cinco es igual al cuartil dos.

CÁLCULO DE LOS DECILES – El cálculo de los deciles es similar al cálculo de los cuartiles, solo que en estos varía la posición, la misma se calcula con la formula:

$P_{Da} = \frac{aN}{10}$, en esta a corresponde al número del decil que se desea calcular, N equivale al número de datos de la distribución y 10 corresponde a las diez partes en la que se divide la serie de valores de la distribución.

$$\text{La fórmula para su cálculo es: } D_a = Li + \left[\frac{\frac{aN}{10} - Faa}{fm} \right] . Ic. \text{ En este caso se aplica la formula de}$$

la misma manera que se hizo para calcular los cuartiles, solo que en esta fórmula varia la posición de ubicación de la clase donde se encuentra ubicado el decil.

F) LOS PERCENTILES – Son medidas posiciónales que dividen la distribución de frecuencia en 100 partes iguales. Con estos se puede calcular cualquier porcentaje de datos de la distribución de frecuencia. Los percentiles son las medidas más utilizadas para propósitos de ubicación de valor de una serie de datos ubicados en una distribución de frecuencia. El número de percentiles de una distribución de frecuencia es de 99. El percentil 50 es igual a la mediana, al decil 5 y al cuartil 2, es decir: $Md = Q_2 = D_5 = P_{50} = 50\%$ por encima y 50 % por de bajo de los datos de la distribución.

El cálculo de los percentiles es similar al cálculo de los cuartiles y los deciles con una variante en la posición de ubicación de estos, que viene expresada por la siguiente fórmula:

$$P_{Pa} = \frac{aN}{100} . \text{ Con esta posición se aplica la formula: } P_a = Li + \left[\frac{\frac{aN}{100} - Faa}{fm} \right] . Ic .$$

1. – Dada la siguiente distribución correspondiente al salario semanal en dólares de un grupo de empleados privados de una clínica de Buenos Aires. Calcule: a) Q_1 , b) Q_2 , c) Compare los resultados con la mediana D_3 , d) D_5 , e) P_{25} , f) P_{50} , g) P_7

SALARIO EN \$	fi	Fa
200-----299	85	85
300-----399	90	175
400-----499	120	295
500-----599	70	365
600-----699	62	427
700-----799	36	463
Totales = N	463	

a) Para calcular Q_1 , se determina primero la posición así: $P_{Q_1} = \frac{1 \times 463}{4} = \frac{463}{4} = 115.75$.

$P_{Q_1} = 115.75$. Con ese valor de la posición encontrado se busca en las frecuencias acumuladas para ver cual de esas contiene ese valor. Observando las frecuencias acumuladas se puede detectar que la posición 115.75 se encuentra en la clase 300-----399, por lo tanto el $Li = 299.5$, $fm = 90$, y la $Faa = 85$ y $Ic = 100$, aplicando la formula se tiene:

$$Q_1 = 299.5 + \left[\frac{115.75 - 85}{90} \right] . 100 = 299.5 + \frac{3075}{90} = 299.5 + 34.17 = 333.67.$$

Este valor de Q_1 indica que el 25 % de los empleados en estudio, devengan un salario semanal por debajo de 333.67 \$ y el 75 % restante gana un salario por encima de 333.67 \$.

b) Para calcular $Q_2 = Md$ se determina primero la posición de este así. $P_{Q_2} = \frac{2 \times 463}{4} = 231.5$, ahora se ubica esta posición en las frecuencias acumulados para determinar la posición de Q_2 , se puede observar en la distribución que esta posición de Q_2 esta ubicada en la clase 400----499, entonces, $Li = 399.5$, $fm = 120$, $Faa = 175$ y $Ic = 100$, aplicando la formula se tiene:

$$Q_2 = 399.5 + \left[\frac{231.5 - 175}{120} \right] \cdot 100 = 399.5 + \frac{5650}{120} \rightarrow 399.5 + 47.08 = 446.58.$$

Este resultado de Q_2 establece que el 50 % de los obreros de este estudio, devengan un salario semanal por debajo de 446.58 \$ y el otro 50 % devenga un sueldo por encima de 446.58 \$. Calcule la mediana y compárela con este resultado.

c) Para determinar $D_3 = P_{30}$ hay primero que calcular la posición de este así: $P_{D_3} = \frac{3 \times 463}{10} = 138.9$, ahora se ubica esta posición en las frecuencias acumuladas para determinar la posición de D_3 , en la tabla de la distribución de frecuencia se observa que D_3 se encuentra en la clase 300----399, luego, $Li = 299.5$, $fm = 90$, $Faa = 85$ y $Ic = 100$, aplicando la formula se tiene:

$$D_3 = 299.5 + \left[\frac{138.9 - 85}{90} \right] \cdot 100 = 299.5 + 59.89 = 359.39.$$

Esto indica que un 30 % de los obreros ganan un salario semanal por debajo de 359.39 \$ y el 70 % restante devenga un sueldo por encima de 359.39 \$.

d) Calcular, $D_5 = Q_2 = P_{50}$, además $P_{25} = Q_1$, la comprobación de estos resultados se le deja como practica al estudiante.

g) Para calcular P_{70} lo primero que se hace es determinar la posición, $P_{P_{70}} = \frac{70 \times 463}{100} = 324.10$.

Ahora se ubica este resultado en la columna de frecuencias acumuladas para encontrar la posición de P_{70} en la distribución de frecuencia. Como se puede observar en la tabla de distribución de frecuencia, P_{70} se encuentra ubicado en la clase 500-----599, entonces, $Li = 499.5$, $fm = 70$, $Faa = 295$ y $Ic = 100$, aplicando la formula se tiene:

$$P_{70} = 499.5 + \left[\frac{324.10 - 295}{70} \right] \cdot 100 = 499.5 + \frac{2910}{70} = 499.5 + 41.57 = 541.07.$$

Esto indica que el 70 % de los obreros devengan un sueldo semanal que esta por debajo de 541.07 \$ y que el 30 % de los restantes obreros, ganan un salario por encima de 541.07 \$.

Porcentajes de valores que están por debajo o por encima de un valor determinado

Muchas veces necesitamos conocer el porcentaje de valores que están por debajo o por encima de un valor determinado; lo que representa un tipo de problema contrario al estudiado anteriormente, esto es, dado un cierto valor en el eje de abscisa (X) del plano cartesiano, determinar en la ordenada (Y) el tanto por ciento de valores inferiores y superiores al valor dado. Operación que se resuelve utilizando la siguiente fórmula matemática:

$$p = \left[faa + \frac{f_i(P - L_i)}{I_c} \right] \frac{100}{N}, \text{ donde:}$$

p = porcentaje que se quiere buscar.

P = Valor dado en el eje de las X (valor que se ubica en las clases).

faa = Frecuencia acumulada de la clase anterior a la clase donde se encuentra ubicado P .

f_i = Frecuencia de la clase donde se encuentra ubicada P .

L_i = Limite inferior de la clase donde se encuentra ubicada P .

I_c = Intervalo de clase.

N = Número total de datos o total de frecuencias.

EJEMPLO: Utilizando los datos de la distribución de frecuencia anterior, Determine que porcentaje de obreros ganan un salario semanal inferior a 450 \$.

Solución:

Datos: $p = ?$, $P = 450$, $faa = 175$, $L_i = 400$, $I_c = 100$, $N = 463$

Ahora se aplica la formula:

$$p = \left[faa + \frac{f_i(P - L_i)}{I_c} \right] \frac{100}{N}, \text{ Sustituyendo valores se tiene:}$$

$$p = \left[175 + \frac{120(450 - 400)}{100} \right] \frac{100}{463} \rightarrow p = 50.75$$

De acuerdo con el resultado se puede afirmar que el 50.75 % de los obreros devengan un salario inferior a 450 \$ y el 49.25 % de los obreros ganan un salario superior a 450 \$.

MEDIDAS DE DISPERSIÓN O VARIABILIDAD

Las medidas de posición central son los valores que de una manera condensada representan una serie de datos, pero realmente no son suficientes para caracterizar una distribución de frecuencia. Para describir una distribución de frecuencia o serie de datos es necesario, por lo menos otra medida que indique la *dispersión* o *variabilidad* de los datos, es decir, su alejamiento de las medidas de

posición central. Estas medidas de posición central no tienen ningún valor si no se conoce como se acercan o se alejan esos valores con respecto al promedio, en otras palabras es conocer como se *dispersan* o *varían* esos valores con respecto al promedio de una distribución de frecuencia.

La dispersión o variabilidad se entiende como el hecho de que los valores de una serie difieran uno de otro, es decir, como se están dispersando o distribuyendo en la distribución. De acuerdo con esto es necesario encontrar una medida que indique hasta que punto los valores de una variable están dispersos en relación con el valor típico. Las medidas de variabilidad son números que expresan la forma en que los valores de una serie de datos cambian alrededor de una medida de posición central la cual por lo general es la media aritmética.

La dispersión puede ser mayor o menor, tomando en cuenta esas diferencias. La variabilidad es la esencia de la estadística, puesto que las variables y atributos se caracterizan siempre por diferencias de valores entre observaciones individuales. Casi siempre en una distribución de frecuencia el promedio obtenido difiere de los datos de la serie; por esto es importante determinar el grado de variación o dispersión de los datos de una serie de valores con respecto al promedio. Las medidas de dispersión se clasifican en dos grandes grupos: **a).- Las Medidas de Dispersión Absolutas y las Relativas; las Relativas, vienen expresadas en las mismas medidas que se identifican la serie de datos, las mismas son: 1).- El Recorrido o Rango , 2) La Desviación cuartílica, 3) La Desviación Semicuartílica. 4) La Desviación Típica o Estándar. 5) La varianza.**

Se llama *Variación o Dispersión* de los datos, el grado en que los valores de una distribución o serie numérica tiende a acercarse o alejarse alrededor de un promedio. Cuando la dispersión es baja indica que la serie de valores es relativamente homogénea mientras que una variabilidad alta indica una serie de valores heterogénea.

Cuando los valores observados de una serie están muy concentrados alrededor del *promedio*, se dice que ese *promedio* es o será muy *representativo*; pero si están *muy dispersos* con relación al promedio, es decir muy esparcidos con respecto al promedio, entonces ese promedio *es poco representativo* de la serie o distribución, puesto que no representan adecuadamente los datos individuales de esa distribución. Es importante obtener una medida que indique hasta qué punto las observaciones de una serie de valores están variando en relación con el valor típico de la serie.

1) RANGO O RECORRIDO(R) -. Es la primera medida de dispersión, no esta relacionada con ningún promedio en particular, ya que este se relaciona con los datos mismos, puesto que su cálculo se determina restándole al dato mayor de una serie el dato menor de la misma, más una unidad de medida (UM). El rango es el número de variables diferentes que posee una serie de valores. Su formula se calcula así:

Rango(R) = Dato mayor (X_M) – Dato Menor (X_m) + Una unidad de medida (1UM):

$R = X_M - X_m + 1 \text{ UM}$. El rango es la medida de dispersión más sencilla e inexacta dentro de las medidas de dispersión absoluta. Esta medida tiene bastante uso en el control de calidad de los productos manufacturados.

2) DESVIACIÓN ÍNTERCUARTILICA (DC). - *La desviación intercuartilica es la diferencia que existe entre el cuartil tres(Q_3) y el cuartil uno(Q_1) de una distribución de frecuencia y se expresa así: $DC = Q_3 - Q_1$.*

3) DESVIACIÓN SEMI-ÍNTERCUARTILICA (DSC). - *La desviación semi-intercuartilica es la diferencia entre el Q_3 y el Q_1 dividido entre dos: $DSC = \frac{Q_3 - Q_1}{2}$.*

Si los valores de la DC o DSC son pequeños indica una alta concentración de los datos de la distribución en los valores centrales de la serie de datos. Estas medidas se utilizan para comparar los grados de variación de los valores centrales en diferentes distribuciones de frecuencias. Los mismos no son afectados por los valores extremos, no se adaptan a la manipulación algebraica, por tal motivo son de poca utilidad.

4) DESVIACIÓN TÍPICA O ESTÁNDAR

Es la *medida de dispersión* más utilizada en las investigaciones por ser la más estable de todas, ya que para su cálculo se utilizan todos los desvíos con respecto a la media aritmética de las observaciones, y además, se toman en cuenta los signos de esos desvíos. Se le designa con la letra castellana *S* cuando se trabaja con una muestra y con la letra griega minúscula σ (Sigma) cuando se trabaja con una población. Es importante destacar que cuando se hace referencia a la población el número de datos se expresa con *N* y cuando se refiere a la muestra el número de datos se expresa con *n*. La desviación típica se define como:

“La raíz cuadrada positiva del promedio aritmético de los cuadrados de los desvíos de las observaciones con respecto a su media aritmética”. La desviación típica es una forma refinada de la desviación media”.

Características de la Desviación Típica:


- * La desviación típica se calcula con cada uno de los valores de una serie de datos.
- * La desviación típica se calcula con respecto a la media aritmética de las observaciones de una serie de datos, y mide la variación alrededor de la media.
- * La desviación típica es susceptible de operaciones algebraicas, puesto que para su cálculo se utilizan los signos positivos y negativos de los desvíos de todas las observaciones de una serie de valores, por lo tanto es una medida completamente matemática.
- * Es una medida de bastante precisión, que se encarga de medir el promedio de la dispersión de las observaciones de una muestra estadística. Las influencias de las fluctuaciones del azar, al momento

de seleccionar la muestra la afectan muy poco. Le da gran significación a la media aritmética de la serie de valores.

* Es siempre una cantidad positiva.


Interpretación de la desviación típica

La desviación típica como medida absoluta de dispersión, es la que mejor nos proporciona la variación de los datos con respecto a la media aritmética, su valor se encuentra en relación directa con la dispersión de los datos, a mayor dispersión de ellos, mayor desviación típica, y a menor dispersión, menor desviación típica. Su mayor utilidad se presenta en una distribución normal, ya que en dicha distribución en el intervalo determinado por $\bar{X} \pm \sigma$ se encuentra el 68,27% de los datos de la serie; en el intervalo determinado por la $\bar{X} \pm 2\sigma$ se encuentra el 95,45% de los datos y entre la $\bar{X} \pm 3\sigma$ se encuentra la casi totalidad de los datos, es decir, el 99,73% de los datos; además, existe una regla general de gran utilidad para la comprobación de los cálculos que dice: “una oscilación igual a seis veces la σ , centrada en la media comprende aproximadamente el 99% de los datos”. Ver gráfica.



A la zona limitada por la $\bar{X} \pm \sigma$ conoce bajo el nombre de zona normal, ya que se considera a los datos que caen dentro de esa zona, datos normales en relación con el grupo estudiado; los datos que estén por encima o por debajo de dicho intervalo se consideran supranormales e infranormales.

En concreto la **regla empírica** indica que en cualquier distribución normal las probabilidades delimitadas entre 1 desviación típica, 2 desviaciones típicas y 3 desviaciones típicas son el 68%, 95% y 99% respectivamente. Ver las graficas siguientes.



Métodos de cálculo

Cálculo de la Desviación Típica.- La desviación típica para calcularla se procede de dos formas: A).- Para datos *no agrupados en clases*, B).- Para datos *agrupados en clases*.

A). - Para datos no Agrupados.- Las formulas para determinar la desviación típica de una población se simbolizan con S : mayúscula o σ :sigma y para datos sin agrupar se calculan ::

(1)

$$\sigma = \sqrt{\frac{\sum (X_i - \bar{X})^2}{N}} = \sqrt{\frac{\sum d_i^2}{N}}$$

(2)

$$\sigma = \sqrt{\frac{\sum X_i^2}{N} - \left(\frac{\sum X_i}{N}\right)^2} = \sqrt{\frac{\sum X_i^2}{N} - \bar{X}^2}$$

(3)

$$s = \sqrt{\frac{\sum (X_i - \bar{X})^2}{n-1}} = \sqrt{\frac{\sum d_i^2}{n-1}}$$

(4)

$$s = \sqrt{\frac{\sum X_i^2 - \frac{(\sum X_i)^2}{n}}{n-1}} = \sqrt{\frac{N \sum X_i^2 - (\sum X_i)^2}{n(n-1)}}$$

Es importante recordar que cuando se trabaja con la formula para datos no agrupados y se trata de una muestra se utilizará como denominador $n-1$, para corregir el sesgo, pero si en la muestra $n \geq 50$ ya practicamente se puede usar de denominador n nomás .

En el caso que se calculo el desvío poblacional primero se puede multiplicar por el factor : $\sqrt{\frac{n}{n-1}}$

$$(5) s = S \cdot \sqrt{\frac{n}{n-1}} \text{ o bien } s = \sigma \cdot \sqrt{\frac{n}{n-1}} ; \text{ se puede demostrar esto matemáticamente}$$

si reemplazamos σ por (1) en (5) : $s = \sqrt{\frac{\sum(x-\mu)^2}{n}} \cdot \sqrt{\frac{n}{n-1}}$ entonces $s = \sqrt{\frac{\sum(x-\mu)^2}{n-1}}$

Método para calcular la Desviación Típica muestral en datos no agrupados:

- * Se calcula la media aritmética.
- * Se calculan los desvíos (d_i) de la serie de valores X_i , con respecto a la media aritmética.
- * Se elevan al cuadrado cada una de las desviaciones (d_i)², y se determina la sumatoria de esos. De la misma forma se elevan al cuadrado cada uno de los X_i y se calcula la sumatoria de estos; de igual manera se calcula la sumatoria de los X_i y se elevan al cuadrado. Despues de hacer todos estos cálculos se elabora un cuadro estadístico con estos cálculos.
- * Finalmente se aplica la formula de la desviación típica para datos no agrupados de la muestra o de la población, según el caso.

Ej.1 – Los siguientes valores corresponden a la edad de niños de una muestra tomada de una población: $X_i = \{3, 4, 5, 6, 7\}$. Determine la desviación típica.

X_i	$(X_i - \bar{X}) = d_i$	d_i^2
3	$3 - 5 = -2$	4
4	$4 - 5 = -1$	1
5	$5 - 5 = 0$	0
6	$6 - 5 = 1$	1
7	$7 - 5 = 2$	4

$$\bar{X} = \frac{\sum X_i}{n} = \frac{25}{5} = 5$$

Este problema se resolverá utilizando la media aritmética y sin utilizar la media, para ello se utilizarán las formulas 3 y 4 o 5 .

$$(3) \quad s = \sqrt{\frac{\sum d_i^2}{n-1}} = \sqrt{\frac{10}{4}} = \sqrt{2.5} = 1.58$$

tambien las alternativas son :

$$4) s = \sqrt{\frac{n \sum X_i^2 - (\sum X_i)^2}{n(n-1)}} = \sqrt{\frac{5(135 - 625)}{5(4)}} = \sqrt{\frac{50}{20}} = 1.58$$

$$5) s = S \cdot \sqrt{\frac{n}{n-1}} = \sigma \cdot \sqrt{\frac{n}{n-1}} = \sqrt{\frac{10}{5}} \cdot \sqrt{\frac{5}{4}} = 1.58$$

Interpretación.- El resultado obtenido con las formulas 1 y 3 indican que en promedio, las edades de los niños de esa muestra se desvian o varían con respecto a la media aritmética en una cantidad igual a 1.58 años.

Si este problema se resuelve ahora, considerando los datos como si fueran de una población y se aplica la formula 1 y 2, entonces se tiene:

$$\sigma = \sqrt{\frac{\sum d_i^2}{N}} = \sqrt{\frac{10}{5}} = \sqrt{2} = 1.41 \quad \text{o bien} \quad \sigma = \sqrt{\frac{\sum X_i^2}{N} - \left(\frac{\sum X_i}{N}\right)^2} = \sqrt{\frac{135}{5} - \frac{625}{5}} = \sqrt{27 - 25} = \sqrt{2} = 1.41.$$

En la solución del problema con las formula 1 y 2 de la población se observa que la σ de la población es menor que la S de la muestra, esto es debido a que la S de la muestra utilizó $n-1$, para corregir el error producto del sesgo, y la σ de la población no lo utilizó.

- 4 – Los años de servicio de una muestra de 6 obreros (son 5, 5, 8, 7, 9, y 11, los mismos corresponde a una muestra tomada de una empresa. Calcule la desviación típica (s).

$\sum X_i = 45$	$\sum d_i = 0$	$\sum d_i^2 = 27.50$	$\sum X_i^2 = 365$
-----------------	----------------	----------------------	--------------------

Con estos datos se aplican las formulas 3 y 1 para calcular el desvío muestral, se deja la formula 3 para que sea aplicada por el participante, el resultado será igual al de la formula 1. Cálculos:

$$s = \sqrt{\frac{\sum d_i^2}{n-1}} = \sqrt{\frac{27.5}{6-1}} = \sqrt{\frac{27.5}{5}} = \sqrt{5.5} = 2.35$$

Ahora si hubiese calculado σ para la población (considerado los datos como de una población).

$$4.- \sigma = \sqrt{\frac{\sum d_i^2}{N}} = \sqrt{\frac{27.5}{6}} = \sqrt{4.58} = 2.14.$$

$$5.- \sigma = \sqrt{\frac{\sum X_i^2}{N} - \left(\frac{\sum X_i}{N}\right)^2} = \sqrt{\frac{365}{6} - \left(\frac{45}{6}\right)^2} = \sqrt{\frac{365}{6} - \left(\frac{2025}{36}\right)} = \sqrt{4.58} = 2.14.$$

Interpretación.- El resultado obtenido al aplicar la formula 1, 2, 3, 4 y 5 indica que en promedio, los años de servicios de los trabajadores de la empresa se desvian o dispersan con respecto a su media aritmética en una cantidad igual a 2.35 año según la muestra y de 2.14 años en la población.

A) – Para datos Agrupados en Clases.- Para calcular la desviación típica en datos agrupado existen varios criterios en relacion a la corrección del sesgo que se produce al tomar una muestra, en este estudio se considerará la formula que corrige el sesgo de aquellas muestras en estudio; sin embargo, cuando n sea mayor que 50, no es necesario tal corrección. . Existen muchas formulas matemáticas para calcular la desviación típica, queda a juicio del estudiante utilizar la formula que él considere más fácil, siempre y cuando su aplicación sea valedera.

B).- Formulas Para calcular la desviación típica con datos agrupados en clases:

Método para calcular la Desviación Típica en datos Agrupados:

* Se calcula la $\bar{X}$

* Se calcula el X_{mi} : Marca de clase (punto medio) de cada una de las clases que integran la distribución de frecuencia, se determinan los desvíos d_i de los X_{mi} con respecto a la $\bar{X}$, luego se elevan al cuadrado los d_i y se multiplican por f_i , y se calcula la $\sum f_i d_i^2$.

Ver ejemplo de cálculo en la siguiente tabla: Linkear [aquí](#)

Ejemplos: 3 – Los siguientes datos corresponden a las horas extras trabajadas por los obreros de la empresa RINACA, en un mes (se resolverá considerando los datos como de una S y σ).

L_i	L_s	f_i	X_{m_i}	$f_i \cdot X_i$	$d_i =$	$f_i d_i^2$
40	44	3	42	42	-15,259	698,535
45	49	12	47	282	-10,259	1263,029
50	54	20	52	1092	-5,259	553,196
55	59	70	57	4275	-0,259	4,705
60	64	20	62	1426	4,741	449,492
65	69	8	67	469	9,741	759,056
70	74	2	72	144	14,741	434,579
		135		7730		4162,59

Media y desvío estándar

$$\bar{X} = 57,26$$

$$S = 5,533$$

Existen estadísticas algunas formulas que se llaman de cálculo por su ahorro en cuanto a la cantidad de operaciones que se necesitan. Por ejemplo como vimos el desvío estándar poblacional

$$S \text{ o } \sigma = \sqrt{\frac{\sum_{i=1}^n f_i \cdot d_i^2}{n}}; \text{ es equivalente a } \sigma = \sqrt{\frac{\sum_{i=1}^n f_i \cdot X_{m_i}^2}{n} - \bar{X}^2} = \sqrt{\frac{4162,59}{135} - 57,26^2} = 5,51267$$

Si ahora quiero convertirlo en el desvío estándar muestral lo multiplico por el factor de conversión

$$\sqrt{\frac{n}{n-1}} = \sqrt{\frac{135}{134}} = 1.0037; \text{ de esta manera } s = S \cdot 1.0037 \text{ o } s = \sigma \cdot 1.0037 = 5.533$$

- 1 – Los siguientes datos corresponden al número de panes consumidos por un grupo de familia de una urbanización de la ciudad, durante una semana determinada.

Para resolver el problema se calcula la media y se procede a llenar el cuadro estadístico siguiente (el estudiante debe realizar los cálculos):

Media muestral

$$\bar{x} = \frac{11520}{288} = 40.0.$$

Clases	f_i
30—32	10
33—35	18
36—38	60
39—41	100
42—44	80
45—47	14
48—50	6
Σ	288

Clases	f _i	x _{mi}	f _i .x _{mi}	f _i .x _{mi} ²	d _i	f _i .d _i ²
30—32	10	31	310	9610	-9	810
33—35	18	34	612	20808	-6	648
36—38	60	37	2220	82140	-3	540
39—41	100	40	4000	160000	0	0
42—44	80	43	3440	147920	3	720
45—47	14	46	644	29624	6	504
48—50	6	49	294	14406	9	486
Σ	288		11520	464508		3708

Interpretación.- Los resultados obtenidos con las formulas 1 y 6 indican que en promedio, el consumo de pan de trigo del grupo de familias de esa urbanización se dispersa con respecto a su media aritmética en una cantidad igual a 3.59.

$$s = \sqrt{\frac{\sum f_i d_i^2}{n-1}} = \sqrt{\frac{3708}{288-1}} = \sqrt{\frac{3708}{287}} = \sqrt{12.92} :$$

Es importante señalar que expertos en la materia consideran que cuando las muestras son superiores a 30 datos el error de sesgo ya no se produce o es insignificante y en consecuencia no es necesario utilizar la formula que se encarga de corregir el mismo, por tal razón es conveniente utilizar n y no, $n-1$.

VARIANZA – Es otra de las variaciones absolutas y la misma se define como el cuadrado de la desviación típica; viene expresada con las mismas letras de la desviación típica pero elevadas al cuadrado, así S^2 y σ^2 . Las formulas para calcular la varianza son las mismas utilizadas por la desviación típica, exceptuando las respectivas raíces, las cuales desaparecen al estar elevados el primer miembro al cuadrado. La varianza general de la población se expresa de la forma siguiente:

DISPERSIÓN RELATIVA.

Las medidas de variabilidad, estudiadas hasta ahora, solo permitían medir las dispersiones *absolutas* de los términos de la muestra. Las medidas, tomadas en esas condiciones, serán de utilidad, solo cuando se trata de analizar una sola muestra; pero, cuando hay que establecer comparaciones entre distintas muestras, será necesario expresar tales medidas en valores *relativos*, que pueden ser *proporciones o porcentajes*.

Las medidas de *dispersión relativas* permiten comparar grupos de series distintas en cuanto a su variación, independientemente de las unidades en que se midan. Generalmente las medidas de *dispersión relativas* se expresan en porcentajes, facilitando así el estudio con medidas procedentes de otras series de valores. *La dispersión relativa viene a ser igual a la dispersión absoluta dividida entre el promedio.*

COEFICIENTE DE VARIACIÓN

Existen varias medidas de *dispersión relativa*, pero, la más usada es *el coeficiente de variación de Pearson*, este es un índice de variabilidad sin dimensiones, lo que permite la comparación entre diferentes distribuciones de frecuencias, medidas **en diferentes unidades**. El coeficiente de variación de Pearson se designa con las letras CV. La fórmula matemática es:

$$CV = s / \text{media} \cdot 100\%$$

Los valores oscilan de 0 a 100% generalmente, no hay ninguna regla estricta sobre su interpretación, no obstante si su valor está de 0 a 20 podemos decir que existe poca variabilidad, casi nula, si está de 20 a 30 la variabilidad es intermedia o moderada, si supera 30 ya es marcada, es decir que existe un importante grado de dispersión respecto a la media.

5 – La venta en el mercado de tres productos, varía de acuerdo al siguiente cuadro. Determine el CV de cada uno y diga cuál de ellos presenta mayor variación y cuál la menor.

Producto	$\bar{X}$	S	Unidades	CV
1	45	5	Bs.	11.11 %
2	450	40	Bs.	8.87 %
3	4500	350	Bs.	7.78 %

Para resolver el problema se calcula el CV de cada producto y luego se determina cuál presenta mayor o menor variación : $CV = S \times 100 / \bar{X}$; $CV_1 = 5 \times 100 / 45 = 11.11 \%$; $CV_2 = 40 \times 100 / 450 = 8.87 \%$. $CV_3 = 350 \times 100 / 4500 = 7.78 \%$.

Se puede observar que la menor dispersión la presenta el producto 3, por lo tanto, de los 3 productos el que menos varía es ese; por otro lado el de mayor dispersión o variabilidad es el producto 1.


Otro ejemplo : Se está estudiando el comportamiento de los turistas que ingresan a la ciudad de Posadas. Para ello se cuenta con una base de datos de donde se pudo obtener que la media de cantidad días de alojamiento es de 3 días, con un desvío estándar de 1,5. Por otra parte se determinó que el gasto diario en la ciudad es de 45 dólares con un desvío de 15 dólares .

Si se quisiera saber en que son más variables los turistas (menos predecibles) no se podría comparar con los desvíos estándar porque están en diferentes unidades (días y dólares). Por lo cual inevitablemente debemos usar el coeficiente de variación .

Resolución: $CV_1 = 1,5 / 3 \cdot 100 = 50\%$ mientras que respecto a los gastos $CV_2 = 15 / 45 \cdot 100 = 33\%$, lo cual significa que son más impredecibles o más variables en cuanto a los días que a los gastos por día.

8. OTRAS MEDIDAS ESTADÍSTICAS: Medidas de Asimetría y Kurtosis

SIMETRÍA.- Según el Diccionario de la Real Academia Española es la “Regularidad en la disposición de las partes o puntos de un cuerpo o figura, de modo que posea un centro, un eje o un plano de referencia”. Es por lo tanto la armonía de posición de las partes o puntos similares uno respecto de otros y con referencia a puntos, líneas o planos determinados. Se puede generalizar diciendo que es una proporción de las partes entre sí y con el todo.



En estadística se dice que una distribución de datos es *simétrica* si se le puede doblar a lo largo de un eje vertical de una manera tal que coincidan los dos lados de la distribución. Las distribuciones que no tienen simetría con respecto al eje vertical se les llama *sesgada* o *asimétrica*. Una distribución sesgada a la derecha tiene una cola prolongada del lado derecho de la distribución y una cola más corta del lado izquierdo de la misma; esta asimetría se le denomina positiva, cuando la cola de la distribución del lado izquierdo es más larga que la del lado derecho, entonces la asimetría es negativa.

En una distribución *simétrica* la media, la mediana y la moda son iguales. La simetría se mide por medio del *coeficiente de asimetría*. Una distribución simétrica tiene un coeficiente de asimetría igual a cero. Cuando una distribución de frecuencia es *asimétrica*, la media, la mediana y la moda se alejan una de otra, es decir, las tres medidas de posición son diferentes; mientras más se separe la media de la moda, mayor es la asimetría. Si la distribución de frecuencia es asimétricamente negativa, la cola de la curva de distribución se encuentra hacia los valores más pequeños de la escala de las X y si la distribución es asimétricamente positiva la cola de la distribución se ubica hacia los valores más grandes de la escala de las X .

Karl Pearson un estudioso de la estadística diseño el coeficiente de asimetría con las letras **SK** y determinó la formula para su cálculo, al cual se le denominó *primer coeficiente de asimetría de Pearson*

$$SK_1 = \frac{(\bar{X} - Mo)}{S}$$

Esta fórmula se puede transformar por medio de la relación:

$$Mo = \bar{X} - 3(\bar{X} - Md) \rightarrow Mo - \bar{X} = -3(\bar{X} - Md) \rightarrow \bar{X} - Mo = 3(\bar{X} - Md)$$

$\bar{X} - Mo = 3(\bar{X} - Md)$, si ahora se sustituye $3(\bar{X} - Md)$ en el *primer coeficiente de asimetría de Pearson*, se tiene otro coeficiente de asimetría utilizando la mediana que se le denomina *segundo coeficiente de asimetría de Pearson*, este es más preciso que el primero

$$SK_2 = \frac{3(\bar{X} - Md)}{S}$$

Arthur Bowley otro estudioso de la estadística determinó que el coeficiente de asimetría se podía calcular por medio de los cuartiles y utilizó el coeficiente de asimetría por medio de cuartiles (sk_q), y la formula es

$$SK_q = \frac{Q_1 + Q_3 - 2Q_2}{Q_3 - Q_1}$$

En donde, Q_1 , Q_2 y Q_3 son los cuartiles 1, 2 y 3 respectivamente. El valor de SK_q varia entre 1 y -1 ; según Bowley una distribución de frecuencia con un coeficiente de asimetría igual a 0.1, se considera como ligeramente asimétrica y con un valor mayor 0.3 se le considera marcadamente asimétrica.

El coeficiente de asimetría se puede calcular también en función de los momentos, siendo el momento m_3 el parámetro utilizado para tal efecto. El coeficiente de asimetría según los momentos se designa con las letras SK_m y se calcula mediante la formula

En esta formula m_3 es el momento tres con respecto a la media aritmética y S^3 es la desviación

$$SK_m = \frac{m_3}{S^3}$$

típica elevada a la potencia tres. Este coeficiente es el más confiable de todos los antes descritos, así que para cualquier calculo se debería utilizar este, ya que es un parámetro que utiliza todos los datos de la serie de valores.

Si en una serie de valores la $\bar{X} > Md > Mo$, entonces la distribución de frecuencia presenta una curva *asimétrica positiva*; si la $\bar{X} = Md = Mo = 0$, la curva de la distribución es *simétrica* y si la

distribución presenta una curva en la que el $Mo > Md > \bar{X}$, entonces se dice que la curva de la distribución *asimétrica negativa*.

Sí la curva de una distribución de frecuencia es sesgada, la media tratara de ubicarse hacia el extremo o lado opuesto, de la serie de valores, donde se concentran los datos. Es bueno hacer referencia que en una asimetría positiva la $\bar{X} > Md$ y en una asimetría negativa la $\bar{X} < Md$.

Si en una distribución de frecuencia, los intervalos de las clases que la conforman presentan frecuencias balanceadas en cada uno de ellos y no presentan ninguna aglomeración especial en los extremos y, además, presenta una concentración de los datos en el centro de la distribución, entonces se dice que la distribución de frecuencia es *simétrica*. Cuando la curva de una distribución de datos es simétrica el $SK = 0$, esta es una de las características de la curva Normal o Campana de Gauss.

Si la mayoría de los datos de una serie de valores están ubicados en el centro de la distribución y, además existe una dispersión medianamente hacia los extremos mayores o menores de las variables, entonces se afirma que la curva de la distribución es *Ligeramente Asimétrica*. Ejemplo

CLASES 1	f ₁	CLASE S 2	f ₂
3—5	5	3—5	8
6—8	10	6—8	12
9—11	25	9—11	20
12—14	40	12—14	40
15—17	20	15—17	25
18—20	12	18—20	10
21—23	8	21—23	5
TOTAL	120	TOTAL	120

En este ejemplo la distribución 1 es ligeramente asimétrica positiva y la distribución 2 es ligeramente asimétrica negativa. La mayoría de las distribuciones de casos reales por lo general son ligeramente asimétricas.

Una distribución de datos es marcadamente asimétrica si la mayoría de los datos de la misma se encuentran ubicados en los extremos mayores o menores de las variables que conforman la distribución. Si la mayoría de los de los datos de una serie de valores se encuentra situados en el extremo de las clases menores de la distribución, entonces la curva de la distribución de frecuencia presenta una asimetría positiva, siendo en este caso el $SK > 0$; y si por el contrario esa mayoría se encuentra en los extremos de las clases mayores de las variables, entonces la serie de valores presenta una curva con una asimetría negativa, luego el Coeficiente de asimetría será mayor que cero, es decir, $SK > 0$

Ejemplos:

CLASES	f_3	CLASES	f_4
3—5	15	3—5	5
6—8	25	6—8	10
9—11	40	9—11	15
12—14	60	12—14	60
15—17	15	15—17	40
18—20	10	18—20	25
21—23	5	21—23	15
TOTAL	17	TOTAL	170

En la distribución 3 los datos presentan una curva marcadamente asimétrica positiva y el caso 4 la curva de la distribución es marcadamente asimétrica negativa.

Existen distribuciones de frecuencias que presentan curvas fuertemente marcadamente asimétricas y otras que las curvas son ligeramente asimétricas. Considerar la asimetría de una curva de frecuencia marcadamente o ligeramente asimétrica, es un asunto de criterio del investigador, puesto que no existen reglas rígidas establecidas que determinen las líneas divisorias o parámetros entre ligeramente o marcadamente asimétrica; Sin embargo cuando la mayoría de los datos de una distribución de frecuencia se ubican en los extremos mayores o menores de las variables se puede afirmar con certeza que la curva de la distribución es marcadamente asimétrica.

Algunos investigadores como Arthur Bowley determinaron que si se aplica el SK_q y ese coeficiente de asimetría obtenido es menor que 0.3 (sin considera el signo) se puede afirmar que la curva de la distribución es *ligeramente asimétrica*, en caso contrario la curva de la distribución sería *marcadamente asimétrica*. Otros investigadores utilizan el coeficiente de asimetría según los momentos (SK_m) para tales efectos, pero no existe criterio en cual ha de ser el coeficiente específico que marque el límite entre ligera y marcadamente. *Sin embargo, en este estudio se considerará que un coeficiente de asimetría según los momentos comprendido entre $-0.30 \leq SK_m \leq 0.30$, sería un buen límite para considerar una curva de distribución como ligeramente asimétrica, de lo contrario sería marcadamente asimétrica.* El SK_m es el coeficiente de asimetría de mayor precisión y confiabilidad, puesto que este, utiliza para su cálculo todos los valores de la serie de datos.

Es bueno afirmar que cuando el coeficiente de asimetría de una curva de distribución es marcadamente asimétrico no se puede utilizar la media aritmética como medida de tendencia central, puesto que esta es afectada altamente por los valores extremos de una serie de datos, en su lugar es recomendable utilizar la mediana como medida de posición.

KURTOSIS8 (CURTOSIS).- Es el grado de apuntamiento o altura de la curva de una distribución de frecuencia. La finalidad de la Kurtosis es determinar si la distribución de los términos de una serie de valores responde a una curva normal o no. Se utiliza para observar el promedio o posición

de la distribución, así como la *media*, la *mediana* y la *moda*, se puede en esta observar la asimetría, el grado de concentración de los datos, en fin, para observar en forma general el comportamiento de una serie de datos en una distribución de frecuencia. Por medio de la Kurtosis se determinará si la distribución de frecuencia es demasiado puntiaguda, normal o muy achatada.

El grado de apuntamiento o altura de una curva de distribución se determina por medio del coeficiente de Kurtosis, el cual se calcula utilizando el momento cuatro de una serie de valores con respecto a su media aritmética. La Kurtosis se designa con la letra K_4 y la formula de cálculo es:

$$K_4 = \frac{m_4}{S^4}$$


En esta fórmula m_4 es el momento cuatro con respecto a la media aritmética y S^4 es la desviación típica elevada a la cuarta potencia, K_4 es el coeficiente de Kurtosis. Tomando en cuenta la Kurtosis el k_4 de una curva de distribución puede ser: *Mesocúrtica*, *Platicúrtica* y *Leptocúrtica*.

Mesocúrticas.- Es aquella curva de una distribución de frecuencia que no es ni muy alta ni muy achatada, es la llamada *curva normal*. La curva Mesocúrtica tiene un coeficiente de Kurtosis igual a tres, es decir, $K_4 = 3$.

Leptocúrtica.- Es aquella curva de la distribución que presenta un apuntamiento o altura relativamente más alta que la curva Mesocurtica, en esta los datos se encuentran más concentrados alrededor del máximo valor. El coeficiente de Kurtosis para curva Leptocurtica es mayor de tres, es decir, $K_4 > 3$.

Platicúrtica.- Es la curva de una distribución de frecuencia que presenta un achatamiento más pronunciado que la Mesocurtica, encontrándose los datos más dispersos alrededor del máximo valor de la distribución. En esta curva el coeficiente de Kurtosis es menor de tres, es decir, $K_4 < 3$.

En la gráfica 1 de Kurtosis se pueden observar los tres tipos de Kurtosis antes descritos, siendo la primera curva *Leptocúrtica*, la segunda *Mesocúrtica* y la última es *Platicúrtica*



Problemas Relacionados con la asimetría y la (Kurtosis) curtosis

1 – En la siguiente distribución de frecuencia, determine el coeficiente de asimetría utilizando los métodos de Pearson, de Bowley y el de los momentos, interprete los resultados y haga un análisis de los diferentes resultados y diga cual es el resultado más recomendado en este caso; encuentre la Kurtosis e interprete los resultados.

CLASES	f_i
10—12	1
13—15	5
16—18	15
19—21	40
22—24	15
25—27	10
28---30	9
Σ	95

Solución.- Para resolver el problema lo primero que hay que hacer es calcular la $\bar{X}$ y determinar los desvíos di con respecto a la media, luego se elabora un cuadro estadístico con el resumen de los cálculos necesarios para determinar la asimetría y la curtosis. Además, se tendrá que calcular la mediana, la moda, el Q_1 el Q_3 , y después de realizar todos esos cálculos se procede a buscar la asimetría y la curtosis con las formulas respectivas. En el siguiente cuadro se encuentran resumidos la mayoría de los cálculos necesarios, el resto se calcularan aparte.

TABLA: Distribución de frecuencia y cálculo

CLASES	f_i	marca	$f_i \cdot x_{mi}$	d_i	$f_i \cdot d_i$	$f_i \cdot d^2$	$f_i \cdot d^3$	$f_i \cdot d^4$
10—12	1	11	11	-10.07	-10.07	101.40	-1021.15	10282.95
13—15	5	14	70	-7.07	-35.35	249.92	-1766.97	12492.45
16—18	15	17	255	-4.07	-61.05	248.47	-1011.29	4115.94
19—21	40	20	800	-1.07	-42.80	45.80	-49.00	52.43
22—24	15	23	345	1.93	28.95	55.87	107.84	208.12
25—27	10	26	260	4.93	49.30	243.05	1198.23	5907.28
28---30	9	29	261	7.93	71.37	565.96	4488.10	35590.60
Σ	95		2002		0.38	1510.40	1945.76	68649.77

Se recomienda al participante que debe realizar los cálculos de los parámetros que solo aparecen sus resultados $\bar{X} = 21.07$, $Mo = 20.0$, $Q_1 = 18.71$, $Q_2 = Md = 20.49$, $Q_3 = 23.55$, $S = 4.41$, $S^2 = 19.46$, $S^3 = 85.82$, $S^4 = 378.82$.

$$SK_1 = \frac{\bar{X} - Mo}{S} = \frac{21.07 - 20.0}{3.99} = \frac{1.07}{3.99} = 0.27$$

El resultado indica que la curva de distribución es ligeramente asimétrica positiva.

$$SK_2 = \frac{3(\bar{X} - Md)}{S} = \frac{3(21.07 - 20.49)}{3.99} = \frac{1.74}{3.99} = 0.44$$

El resultado indica que la curva de la distribución es marcadamente asimétrica positiva.

$$SK_q = \frac{Q_1 + Q_2 - 2Q_2}{Q_3 - Q_1} = \frac{18.71 + 23.55 - 2(20.49)}{23.55 - 18.71} = \frac{1.28}{4.84} = 0.26.$$

El resultado indica que la curva es ligeramente asimétrica positiva.

Para calcular el coeficiente de asimetría según los SK_m se calcula primero el m_3 así:

$$m_3 = \frac{\sum f_i d_i^3}{n} = \frac{1945.76}{95} = 20.48 \quad SK_m = \frac{m^3}{S^3} = \frac{20.48}{63.40} = 0.32$$

El coeficiente SK_m indica que la curva de la distribución es marcadamente asimétrica positiva. Si se observan los diferentes coeficientes de asimetría se puede notar que el SK_2 y el SK_m son marcadamente asimétricos y los otros son ligeramente asimétricos, esto es así por cuanto el valor obtenido con el SK_2 y el SK_m son más precisos que los otros, lo que indica que se debe preferir el

$$m_4 = \frac{\sum f_i d_i^4}{n} = \frac{68649.77}{95} = 722.63$$

resultado de estos últimos por razones obvias. Siempre el SK_m será más preciso que cualquier otro coeficiente de asimetría, ¿Por qué? Los resultados obtenidos con los diferentes coeficientes de *asimetría* indican que esta es *positiva*, es decir, con un sesgo hacia la cola de la derecha. Para

$$K_4 = \frac{m_4}{S^4} = \frac{722.63}{252.8} = 2.86.$$

calcular el K_4 se calcula el m_4 así: Ahora se procede a calcular el K_4 aplicando la formula

El resultado indica que el apuntamiento de la curva es ligeramente achatado , ya que está próxima a 3.

2- Dada la siguiente distribución de frecuencia determine el SK_1 , el SK_2 , el SK_q , el SK_m , haga un análisis cada uno de estos y diga cual es el más recomendado, tomando en cuenta la precisión de cada uno. Determine, además, el K_4 e interprete el resultado. Se desea tomar una medida de posición central, ¿cuál sería la más adecuada?

CLASES	f_i
40—44	2
45—49	7
50—54	23
55—59	75
60—64	21
65—69	6
70—74	1
Σ	135

Solución.- Para resolver el problema se debe calcular primero la $\bar{X}$ luego se determinan los desvíos con respecto a la $\bar{X}$, se calcula la Md, el Mo., el Q_1 , el Q_3 , la S, el m_3 y el m_4 . Para facilitar el estudio es conveniente elaborar un cuadro estadístico con todos los parámetros necesarios. En el siguiente cuadro se resumen gran parte los parámetros necesarios para resolver el problema.

Solución : *Se arma la tabla completa (se sugiere trabajar con Excel)*

CLASES	f_i	X_{mi}	$f_i \cdot X_{mi}$	d_i	$f_i \cdot d_i$	$f_i \cdot d_i^2$	$f_i \cdot d_i^3$	$f_i \cdot d_i^4$
40—44	2	42	84	-14.74	-29.84	434.54	-6405.05	94410.42
45—49	7	47	329	-9.74	-68.18	664.07	-6468.07	62999.03
50—54	23	52	1196	-4.74	-109.02	516.75	-2449.42	11610.24
55—59	75	57	4275	0.26	19.50	5.07	1.32	0.34
60—64	21	62	1302	5.26	110.46	581.02	3056.16	16075.42
65—69	6	67	402	10.26	61.56	631.60	6480.27	66487.60
70—74	1	72	72	15.26	15.26	232.87	3553.56	54227.32
Σ	135		7660		-0.26	3065.92	-2231.23	305810.37

Se recomienda al participante realizar los cálculos de los parámetros aquí utilizados:

$$\bar{X} = 56.74, \quad Md = 56.87, \quad Mo = 56.95, \quad Q_1 = 54.62, \quad Q_3 = 59.12, \quad S = 4.76, \quad S^3 = 108.23, \\ S^4 = 515.77, \quad m_3 = -16.53, \quad m_4 = 2265.26.$$

Este coeficiente indica que la curva de la distribución es ligeramente asimétrica negativa. Con este resultado se observa que la curva de la serie de valores es casi simétrica.

$$a).....SK_1 = \frac{\bar{X} - Mo}{S} = \frac{56.74 - 56.95}{4.76} = \frac{-0.21}{4.76} = -0.04.$$

Se puede observar que este resultado es un poco mayor que el obtenido con SK1; la curva de acuerdo con este, es ligeramente asimétrica *negativa*.

$$b).....SK_2 = \frac{3(\bar{X} - Md)}{S} = \frac{3(56.74 - 56.8)}{4.76} = \frac{3(-0.16)}{4.76} = -0.10.$$

$$c).....SK_q = \frac{Q_1 + Q_3 - 2Q_2}{Q_3 - Q_1} = \frac{54.62 + 59.12 - 2(56.87)}{59.12 - 54.62} = \frac{0.0}{4.5} = 0.0.$$

Con este coeficiente se observa que la curva es simétrica ya que su coeficiente de asimetría es igual

$$d).....SK_m = \frac{m_3}{S^3} = \frac{-16.53}{108.23} = -0.15$$

a cero. Se puede concluir que este coeficiente no es lo suficiente preciso, puesto que esa curva de distribución no es simétrica, como se puede observar en la distribución de la serie de valores.

Este resultado indica que la curva de la distribución es ligeramente *asimétrica negativa*, este es bastante parecido al obtenido con el SK_2 , los cuales se acercan bastante a la realidad, por lo tanto, el resultado más recomendado para tomar una decisión sería el SK_m , por cuanto en el cálculo del mismo intervienen todos los valores de la serie de datos. Se pudo detectar que en el orden de prioridades referente al coeficiente de asimetría los más indicados serían el SK_m , luego el SK_2 y el menos recomendado sería el SK_q por no adaptarse a la realidad.

Para calcular el K_4 se procede de la siguiente manera:

$$K_4 = \frac{m_4}{S^4} = \frac{2265.26}{515.95} = 4.39.$$

De acuerdo con este resultado la curva de la distribución es Leptocurtica, por ser mayor que el coeficiente de Kurtosis de la curva normal. Este resultado indica que la mayoría de los datos se encuentran ubicados alrededor de la moda y por lo tanto la curva en cuestión presenta un apuntamiento bastante alto.

3.- Los pesos en Kg, de una familia son 4, 35, 39, 40, 42, 48 y 58. Para realizar una investigación se requiere tomar una medida de posición. ¿Cuál es la más adecuada?. Explique brevemente.

Solución. – Para tomar la decisión es necesario calcular el SK_m .

Para calcular el SK_m se determina la $\bar{X}$ de los valores y los desvíos d_i con respecto a esta, se determina la S , la S^3 , el d_i , el d^2 y el d^3 de los datos y la sumatoria de estos, luego se calcula el m_3 y se procede a determinar el SK_m , se elabora un cuadro estadístico con el resumen de los datos requeridos; y se aplica la fórmula respectiva para este caso. El siguiente cuadro resume los datos necesarios para los cálculos

X_i	d_i	d^2	d^3
4	-34	1156	-39304
35	-3	9	-27
39	1	1	1
40	2	4	8
42	4	16	64
48	10	100	1000
58	20	400	8000
$\Sigma X_i = 266$	$\Sigma d_i = 0$	$\Sigma d^2 = 1686$	$\Sigma d^3 = -30258$

$$\bar{X} = \frac{\sum X_i}{n} = \frac{266}{7} = 38.$$

$$S = \sqrt{\frac{\sum d_i^2}{n}} = \sqrt{\frac{1686}{7}} = \sqrt{240.86} = 15.52., S^3 = 3738.$$

$$m_3 = \frac{d^3}{n} = \frac{-30258}{7} = -4322.57.$$

$$SK_m = \frac{-4322.57}{3738} = -1.16.$$

De acuerdo con el resultado, la curva de la distribución es marcadamente asimétrica negativa, lo que indica que existen valores extremos, por lo tanto la media aritmética no se puede utilizar como medida de posición central por ser esta afectada por los valores extremos, en su lugar se utilizará la mediana como medida de posición central, por no ser esta, afectada por los valores extremos.

Los coeficientes SK_1 , SK_2 y sk_q , se le dejan al participante para que los calcule e interprete los resultados dando su opinión al respecto

BIBLIOGRAFÍA

- Daniel Wayne W. Bioestadística: Base para el análisis de las ciencias de la salud
- Rius, F. J. Barón, E . Bioestadística. Métodos y Aplicaciones -
- **Hamlet Mata Mata , Prof. Del TECNOLÓGICO DE EL TIGRE – VENEZUELA , de la página**

DIRECCIONES DE INTERNET QUE HAN SIDO CONSULTADAS

- <http://www.mipagina.cantv.net/hamletmatamata/Documentos.htm> .
- <http://www.mipagina.cantv.net/hamletmatamata>,
- <http://www.lt.bioestadistica.uma.es> , <http://www.uaq.mx/matematicas/estadisticas/xu3.html>
- <http://www.festadistica.fguam.es/indicadores/ipri.html>
- <http://www.uaq.mx/matematicas/estadistica/xu3.html>
- <http://www.estadisticaparatodos.es/curriculo/proyectos.html>